

N17 Дана выборка. Найдите главные направления и дисперсии по главным компонентам.

x_1	4	0	-1	3	4
x_2	2	-3	-2	1	2
x_3	3	2	2	1	-3

Решение:

$$X = \begin{pmatrix} 4 & 2 & 3 \\ 0 & -3 & 2 \\ 1 & -2 & 2 \\ 3 & 1 & 1 \\ 4 & 2 & -3 \end{pmatrix} \begin{matrix} \rightarrow \text{признаки} \\ \rightarrow \text{объекты} \end{matrix}$$

1) Центрируем. Находим среднее и вычитаем из каждой компоненты.

$$\bar{x} = (2, 0, 1), \quad X_c = \begin{pmatrix} 2 & 2 & 2 \\ 2 & -3 & 1 \\ -3 & -2 & 1 \\ 1 & 1 & 0 \\ 2 & 2 & -4 \end{pmatrix}$$

$$2) \quad C = X_c^T X_c = \begin{pmatrix} 2 & 2 & -3 & 1 & 2 \\ 2 & -3 & -2 & 1 & 2 \\ 2 & 1 & 1 & 0 & -4 \end{pmatrix} \begin{pmatrix} 2 & 2 & 2 \\ 2 & -3 & 1 \\ -3 & -2 & 1 \\ 1 & 1 & 0 \\ 2 & 2 & -4 \end{pmatrix} = \begin{pmatrix} 22 & 21 & -9 \\ 21 & 22 & -9 \\ -9 & -9 & 22 \end{pmatrix}$$

$$\frac{1}{n-1} C = \begin{pmatrix} 5,5 & 5,25 & -2,25 \\ 5,25 & 5,5 & -2,25 \\ -2,25 & -2,25 & 5,5 \end{pmatrix} \quad \text{— выборочная матрица ковариаций}$$

3) Найдём п.э. и п.в. C .

$$\det(C - \lambda I) = \begin{vmatrix} 22-\lambda & 21 & -9 \\ 21 & 22-\lambda & -9 \\ -9 & -9 & 22-\lambda \end{vmatrix} = (\lambda-1)(\lambda-16)(\lambda-49) = 0.$$

$$\lambda_1 = 1, \quad v_1 = \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix}$$

$$\lambda_2 = 16, \quad v_2 = \begin{pmatrix} 1/3 \\ 1/3 \\ 1 \end{pmatrix}$$

$$\lambda_3 = 49, \quad v_3 = \begin{pmatrix} -3/2 \\ -3/2 \\ 1 \end{pmatrix}$$

Собственные вектора нормируем:

$$v_1 = \frac{\sqrt{2}}{2} \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix}, \quad v_2 = \frac{\sqrt{11}}{11} \begin{pmatrix} 1 \\ 1 \\ 3 \end{pmatrix}, \quad v_3 = \frac{\sqrt{22}}{22} \begin{pmatrix} -3 \\ -3 \\ 2 \end{pmatrix}$$

v_1, v_2, v_3 - главные компоненты

$$\frac{1}{N-1} s_1^2 = \frac{1}{N-1} b_1^2 = \frac{1}{4} = 0,25$$

$$\frac{1}{N-1} s_2^2 = \frac{1}{N-1} b_2^2 = 4$$

$$\frac{1}{N-1} s_3^2 = \frac{1}{N-1} b_3^2 = \frac{49}{4} = 12,25$$

дисперсии по
главным ком-
понентам

Видим, что 3^я компонента наиболее объясняет
линейную дисперсию стандартизованных при-
знаков, а, например, 1^я - значительно мень-
ше. В задании пометили размерности при-
знаков можно было бы попробовать избавиться
от 1 компонента и посмотреть на резуль-
тат

№35 Задача восстановления регрессии с квадратичной
функцией потерь $L(y', y) = (y' - y)^2$. Док-ть,
что если $f^*(x) = \arg \min_c E((Y - c)^2 | X = x)$, то
 $f^*(x) = E(Y | X = x)$ - регрессионная ф-я.
Какая тогда равен средний риск $R(f^*)$?

Решение: ~~функция потерь~~ L

используемая д-я формула:

$$R(f) = E L(f(X), Y) = \int_{X \times Y} L(f(x), y) p(x, y) dx dy$$

т.е. ожидаемые ф-я потерь, средний риск или
ожидаемая ошибка предсказания

$$R(f) = \int_X \int_Y L(f(x), y) p(y|x) dy p(x) dx$$

$$\int p(x, y) dx dy = p(x) dx \int p(y|x) dy$$

1) для квадратичной ф.и.и. потерь:

$$R(f) = \int_{\tilde{X}} \int_{\tilde{Y}} (f(x) - y)^2 p(y/x) dy p(x) dx = \int_{\tilde{X}} \underbrace{E((f(x) - Y)^2 | x)}_{\rightarrow \min} p(x) dx$$

в задаче восстановления регрессии $R(f) \rightarrow \min_f$, минимизировать можно поочередно:

$$f^*(x) = \arg \min_c E((c - Y)^2 | x) \quad \text{фиксир. } x$$

$$\frac{\partial}{\partial c} E((c - Y)^2 | x) = 0 \quad - \text{найдём из этого условия}$$

$$\begin{aligned} \frac{\partial}{\partial c} \int_{\tilde{Y}} (c - y)^2 p(y/x) dy &= 2 \int_{\tilde{Y}} (y - c) p(y/x) dy = \\ &= 2 \left(\underbrace{\int_{\tilde{Y}} y p(y/x) dy}_{"E(y/x)} - \underbrace{\int_{\tilde{Y}} c p(y/x) dy}_{"c \cdot 1"} \right) \stackrel{(*)}{=} \end{aligned}$$

$$\stackrel{(*)}{=} 2(E(y/x) - c) = 0 \Rightarrow c = E(y/x)$$

т.к. решение $\forall x \in \tilde{X}$, то обобщим для всего множества:

$$f^*(x) = E(Y | X=x) \quad \text{з.м.р.}$$

П.о. в случае квадратичной ф.и.и. потерь наилучшим предсказанием y в ответ на вход x является среднее (регрессионная ф.и.)

$R(f^*)$ — байесовский риск (неукорректированная ошибка)

2) Пока $R(f^*)$ докажем: $R(f^*) = E_x D_y(Y/X)$:

$$\begin{aligned} R(f^*) &= \int_{\tilde{X}} \int_{\tilde{Y}} (f^*(x) - y)^2 p(y/x) dy p(x) dx = \\ &= \int_{\tilde{X}} p(x) \left[\int_{\tilde{Y}} (E(y/x) - y)^2 p(y/x) dy \right] dx = \\ &= E_y \left((E_y(y/x) - y)^2 | x \right) \stackrel{\Delta}{=} \int_{\tilde{X}} p(x) D_y(y/x) dx \stackrel{\Delta}{=} \\ &\stackrel{\Delta}{=} E_x(D_y(y/x)) \quad \text{з.м.р.} \end{aligned}$$

№36 Задача восстановления регрессии с ф.ст
 потерь $L(y', y) = |y' - y|$. Док-м, что мин-
 имизируя среднюю функцию потерь, получаем
 условный медиану $f^*(x) = \text{median}(Y/X=x)$

Решение:

$$R(f) = \int_{\mathbb{R}} p(x) \left[\int_{\mathbb{R}} |f(x) - y| p(y/x) dy \right] dx \rightarrow \min$$

минимизировать можно поочередно:

$$\int_{\mathbb{R}} |c - y| p(y/x) dy \rightarrow \min, \text{ т.е. } \frac{\partial}{\partial c} E[L(c, y)/x] = 0$$

$$\frac{\partial}{\partial c} \int_{\mathbb{R}} L(c, y) p(y/x) dy = \frac{\partial}{\partial c} \int_{\mathbb{R}} |c - y| p(y/x) dy =$$

$$= \int_{\mathbb{R}} \text{sign}(c - y) p(y/x) dy = \int_{-\infty}^c \text{sign}(c - y) p(y/x) dy +$$

$$+ \int_c^{+\infty} \text{sign}(c - y) p(y/x) dy = P(\{c > y\}/x) - P(\{c < y\}/x) =$$

$$= 0 \Rightarrow P(\{c > y\}/x) = P(\{c < y\}/x)$$

Если $p(y/x)$ - непрерывно, то $P(\{c = y\}/x) = 0$

$$\Rightarrow P(\{c \geq y\}/x) = P(\{c \leq y\}/x) = \frac{1}{2}$$

$$\Rightarrow c = \text{median}(Y/X)$$

т.к. рассматриваем $\forall x \in X$, то обобщим на все $x \in \mathbb{R}$:

$$f^*(x) = \text{median}(Y/X=x) \quad \text{ч.т.д.}$$

1/37. Как должно выглядеть фл ютер, чтобы минимизировать среднюю длину гавана условная мера?

Решение:

$$R(f) \rightarrow \min_f \Leftrightarrow E_y (h(y) | x) \rightarrow \min_c \quad \text{фиксир.}$$

$$\min_c \int_{\mathbb{R}} L(c, y) p(y|x) dy \rightarrow \min_c$$

$$f^*(x) = \text{mode}(Y|X=x) \Rightarrow p(c^*/x) \rightarrow \max$$

$$\text{при фиксир. } x \text{ и } f^*(x) = c^*: c^* = \text{mode}(Y/x) \Rightarrow \\ \Rightarrow p(c^*/x) = \max_y p(y/x)$$

$$\Rightarrow c^* = \text{mode}(Y/x) \Rightarrow -p(c^*, x) = \min_c (-p(c, x))$$

$$\int_{\mathbb{R}} L(c, y) p(y|x) dy = -p(c, x)$$

гипотеза-фл Дирха условно-вер-ю: $-L(c, y) = \delta(c-y) = \delta(y-c)$
свво: $\int_{\mathbb{R}} f(x) \delta(x-x_0) dx = f(x_0)$

$$L(c, y) = -\delta(y-c), \text{ так } \delta(y-c) \geq 0, L(c, y) \geq 0, \text{ то} \\ \text{добавим: } \alpha > 0: \quad \boxed{L(c, y) = \alpha - \delta(y-c)}$$

N4.1 Док-ть, что можно положить $v_0 = \bar{x}$. Опи-
сать ми v_0 всех возможных v_0 дает - $\min \sum ()^2$
расстояние до искомого многообразия.

Решение:

$W_k = v_0 + L(v_0, v_a, v_x)$ - k -мерное линейное многообраз.
 $\sum_{i=1}^N \text{dist}^2(x^{(i)}, W_k) \rightarrow \min$

$$\& \quad W_0 = v_0 \in \mathbb{R}^d, \quad \|v_0\| = 1$$

$$W_0 = \arg \min_{v_0 \in \mathbb{R}^d} \sum_{i=1}^N \text{dist}^2(x^{(i)}, v_0) = \arg \min_{v_0 \in \mathbb{R}^d} \sum_{i=1}^N \|x^{(i)} - v_0\|^2 = 0$$

$$\frac{d}{dv_0} \bigcirc = 0 : \quad \sum_{i=1}^N \frac{d}{dv_0} (\|x^{(i)} - v_0\|^2) = 0.$$

$$\sum_{i=1}^N \left(\frac{d(x^{(i)} - v_0)}{dv_0} \cdot \frac{d(\|x^{(i)} - v_0\|^2)}{d(x^{(i)} - v_0)} \right) = 0$$

$$\sum_{i=1}^N (-1) \cdot 2 \cdot (x^{(i)} - v_0) = 0 \quad \left(-\frac{1}{2} \right)$$

$$\sum_{i=1}^N (x^{(i)} - v_0) = 0 \Rightarrow \sum_{i=1}^N x^{(i)} - v_0 \sum_{i=1}^N 1 = 0$$

$$\sum_{i=1}^N x^{(i)} - N \cdot v_0 = 0 \Rightarrow \sum_{i=1}^N x^{(i)} = N \cdot v_0$$

$$\Rightarrow v_0 = \frac{1}{N} \sum_{i=1}^N x^{(i)} = \bar{x} \quad \text{zmp}$$